



Máster Universitario
en **Ciberseguridad**



VNiVERSIDAD
D SALAMANCA

CIBERINTELIGENCIA

Taller OSINT: Selenium, Sherlock y
Obsidian


Sergio Alonso (sergio.alro@usal.es)

**Máster Universitario
en Ciberseguridad**



Taller OSINT – Selenium, Sherlock y Obsidian

Hoy





Taller OSINT – Selenium, Sherlock y Obsidian

Entorno de trabajo



Selenium

Google Colab

Abre el notebook del taller
(enlace en Studium).
Nada que instalar.



Sherlock

Terminal

```
pipx install sherlock-project
```

Alternativa: pip install
sherlock-project



Obsidian

Aplicación de escritorio

obsidian.md/download
Crea un vault vacío:
taller-osint

Instala Sherlock y Obsidian en segundo plano mientras hacemos Selenium.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Caso inicial

Supongamos que recibimos la siguiente información:

 **Correo:** chamoso@usal.es

No conocemos:



Nombre completo



Perfiles en redes



Dirección



Teléfono

Únicamente disponemos de una dirección de correo electrónico.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Caso inicial - Pregunta

¿Cómo comenzarías la investigación?

¿Buscarías el correo directamente en Google?

¿Qué te dice el propio correo? (usuario y dominio)

¿Probarías el alias en otras redes sociales? (SOCMINT – Social Media Intelligence)

¿Consultarías la web de la organización o registros públicos?

¿Qué información necesitarías obtener primero?





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Dato, información e inteligencia

Dato — Elemento aislado que, por sí mismo, aporta poco significado.

Ejemplos: un nombre de usuario, una dirección IP, un número de teléfono, una matrícula.

Información — Conjunto de datos organizados que adquieren contexto.


Inteligencia — Información analizada y verificada que permite apoyar una decisión.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)


El ciclo de inteligencia





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

El ciclo de inteligencia





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Necesidad de información

Todo empieza con alguien que tiene que decidir algo.

Antes de buscar nada, hay que saber:



¿Quién lo pide?

El destinatario: una dirección, un cliente, un equipo de respuesta.



¿Qué decisión apoya?

Qué hará con la respuesta. Eso marca qué es relevante y qué no.



¿Para cuándo?

El plazo decide hasta dónde podemos profundizar.



En el caso inicial

«Nos escribe chamoso@usal.es pidiendo acceso a un documento interno. ¿Es quien dice ser?»

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Planificación

La necesidad se convierte en preguntas concretas y en un plan.

Preguntas

Dividir la necesidad en preguntas que se puedan responder.

Fuentes

Dónde puede estar la respuesta: webs, redes, registros, prensa.

Herramientas

La más sencilla que sirva: API, RSS, scraping, Selenium...

Límites

Legales (RGPD), éticos, OPSEC y tiempo disponible.

En el caso inicial

1. ¿Existe esa persona en la USAL?
2. ¿Usa el alias «chamoso» en otras plataformas?
3. ¿Coinciden los datos entre fuentes?

Elegir la herramienta también es planificar.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Obtención

Recogemos datos de fuentes abiertas y anotamos de dónde sale cada uno.

Manual

Buscadores, operadores avanzados, webs institucionales.



Automatizada

APIs, RSS, scraping, Selenium, Sherlock.



Registro

URL, fecha y hora, captura. Sin esto no se puede verificar.

Hoy en el taller:

 **Selenium** · tendencias del día



Sherlock · un alias, cientos de webs

Un dato sin fuente ni fecha no se puede verificar.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Procesamiento

Ponemos orden: de datos en bruto a información utilizable.

01 Limpiar

Quitar duplicados, ruido y enlaces rotos.

02 Normalizar

Mismo formato para fechas, nombres e idiomas.

03 Filtrar

Descartar falsos positivos y lo irrelevante.

04 Estructurar

Tablas, notas, entidades y relaciones.



En el caso inicial

Sherlock devuelve decenas de URLs. ¿Cuántas son de verdad la misma persona?

Procesar no es analizar: todavía no hay conclusiones.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Análisis

Es la fase más importante.

El investigador debe:

01
Relacionar
datos

02
Detectar
patrones

03
Identificar
inconsistencias

04
Formular
hipótesis

05
Confirmarlas o
descartarlas

Los datos se transforman en inteligencia durante el análisis.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Difusión

La inteligencia solo sirve si llega a quien decide, a tiempo.



Destinatario: quién lo lee y qué sabe ya.



Formato: informe, briefing oral, grafo... el que le sirva.



Confianza: separar hechos de valoraciones y graduar la certeza.



Fuentes: cada afirmación, trazable hasta su origen.

Ejemplo de producto

Conclusión: el alias pertenece probablemente a la persona investigada.

Confianza: media (dos fuentes independientes).

Fuentes: enlaces y fecha de consulta.



Hoy: Obsidian, notas enlazadas y grafo

Separa siempre lo que sabes de lo que supones.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Retroalimentación

Cada respuesta abre preguntas nuevas: el ciclo vuelve a empezar.



¿Respondimos a la necesidad?


El destinatario dice qué le sirvió y qué le falta.



¿Qué aprendimos del proceso?

Fuentes que fallaron, herramientas que sobraron.

En el caso inicial



El ciclo no se cierra: se reinicia con mejores preguntas.

Necesidad

Planificación

Obtención

Procesamiento

Análisis

Difusión

Retroalimentación





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Idea clave

Una buena investigación no depende de la herramienta utilizada.

Depende de:

01 Tener un objetivo claro.

02 Aplicar un método.

03 Verificar la información.

04 Documentar el proceso.

05 Extraer conclusiones fundamentadas.





Taller OSINT – Selenium, Sherlock y Obsidian


El taller en el ciclo





Taller OSINT – Bloque 1 · Selenium

Estamos aquí





Taller OSINT – Bloque 1 · Selenium

Qué vamos a hacer

01



Conceptos

Cuándo usar
Selenium, cómo
funciona y sus límites

02



Demo 1

TT de hoy en
getdaytrends
01_getdaytrends

03



Demo 2

La crisis de Ceuta en
40 días de TT
02_ceuta

04



RSS

La noticia detrás del
TT
03_rss

05



Tarea

Qué hay que entregar
y cómo

Ejecutáis los notebooks conmigo: no hace falta escribir código.





Taller OSINT – Bloque 1 · Selenium

¿Hace falta Selenium?

más coste y más fragilidad

1 API oficial

Datos estructurados y con permiso. Si existe, es la primera opción.

2 RSS / feeds

El sitio publica sus novedades para programas. Lo vemos al final del bloque.

3 requests + HTML

Descargar la página y leer el HTML. Basta si el contenido ya viene en él.

4 Selenium

Un navegador real: para contenido que carga JavaScript o exige clics y scroll.

Selenium es el último recurso, no el primero.





Taller OSINT – Bloque 1 · Selenium

requests frente a un navegador

quotes.toscrape.com

Las citas vienen escritas en el HTML

```
<div class="quote">
  <span class="text">"The world..."</span>
```

✓ requests

✓ Selenium

quotes.toscrape.com/js

El HTML trae un script que pinta las citas

```
<script>
  var data = [{ "text": "..." }]
```

✗ requests

✓ Selenium


¿Y getdaytrends? Las 50 tendencias ya vienen en el HTML: para las de hoy bastaría requests. Selenium aporta cuando hay que interactuar (botones, calendario, scroll).






Taller OSINT – Bloque 1 · Selenium

Cómo funciona Selenium



El ciclo de cualquier script:



Headless: el navegador funciona sin abrir ventana. Es lo que usamos en Colab.





Taller OSINT – Bloque 1 · Selenium

¿Qué es localizar un elemento?

Una web está hecha de etiquetas. Para que Selenium lea o pulse algo, hay que describirle **cuál**: esa descripción es un **localizador**.

```
<div id="trends">
  <table class="tabla">
    <tr>
      <td>
        <a href="/trend/Ceuta/">
          Ceuta
        </a>
      </td>
    </tr>
  </table>
</div>
```

HTML simplificado de la tabla de getdaytrends

<div> <table> <a> La etiqueta

El tipo de elemento: un bloque, una tabla, un enlace.

id="trends" Su nombre propio

Único en la página, como un DNI.

class="tabla" Su grupo

Muchos elementos pueden compartirla, como un uniforme.

href="..." Un atributo

Un dato extra. En un enlace, a dónde lleva.

Ceuta El texto

Lo que se ve en pantalla: lo que queremos extraer.

Para verlo en cualquier web: clic derecho → Inspeccionar.



Tres formas de localizar

By . ID

Por su nombre propio

Si el elemento tiene id, basta con decirlo. Es único: no hay confusión posible.

```
By.ID, "trends"
```

→ *El bloque de tendencias*

By . CSS_SELECTOR

Por su descripción

Tipo de etiqueta, clase y qué está dentro de qué. En CSS, # indica un id y . una clase.

```
By.CSS_SELECTOR, "#trends a"
```

→ *Todos los enlaces del bloque*

By . XPATH

Por su camino

Recorre la página de etiqueta en etiqueta y admite condiciones, como «que el enlace lleve a /trend/».

```
By.XPATH, "//a[contains(@href, '/trend/')] "
```

→ *Los enlaces a tendencias*

Describe el elemento por lo que es, no por dónde está

«La casa de la puerta roja» sigue valiendo aunque construyan otra casa en la calle; «la tercera casa» deja de valer.

```
//*[@id="trends"]//a[contains(@href, "/trend/")]
```





Esperas: a una condición, no a un reloj

⊗ Espera fija

```
time.sleep(5)  
wd.find_element(By.ID, "trends")
```

Espera 5 s aunque la página cargue en 1. Y si tarda 6, falla.

✓ Espera explícita

```
WebDriverWait(wd, 10).until(  
    EC.presence_of_element_located(  
        (By.ID, "trends")))
```

Espera lo justo: sigue en cuanto aparece el elemento, con un máximo de 10 s.

Esperar a que algo ocurra, no a que pase el tiempo.





Interactuar con la página

Clic

```
boton.click()
```

Si el elemento está fuera de pantalla o tapado, el clic falla. Primero, scroll.

Scroll con JavaScript

```
wd.execute_script(  
    "arguments[0]  
    .scrollIntoView();", el)
```

Selenium ejecuta JavaScript dentro de la página: scroll, clics forzados, leer datos.



Publicidad dinámica: los anuncios que cargan tarde cambian la estructura o tapan botones.





Taller OSINT – Bloque 1 · Selenium

Errores típicos y qué hacer

Excepción	Qué significa	Qué hacer
<code>NoSuchElementException</code>	El localizador no encuentra nada	Revisa el selector; ¿la página ha cargado? ¿ha cambiado el HTML?
<code>TimeoutException</code>	La espera explícita llegó al máximo	La condición no se cumple o la web va lenta: reintenta o revisa la condición
<code>ElementClickInterceptedException</code>	Algo tapa el elemento	Scroll al elemento, cerrar el anuncio o banner, o clic con JavaScript
<code>StaleElementReferenceException</code>	La página cambió después de localizarlo	Vuelve a localizar el elemento justo antes de usarlo

Nunca except: pass. Capturad la excepción y mostrad el mensaje.





Taller OSINT – Bloque 1 · Selenium

Límites: ¿podemos hacerlo?



Términos de uso

¿Qué permite el sitio?



robots.txt

Qué rutas pide no automatizar



Ritmo

Pausas entre peticiones; no saturar el servidor



Datos personales

Público no significa libre (RGPD)

Caso real: términos de uso de getdaytrends

Permiten copiar información puntual y hacer capturas de algunas páginas.

Prohíben cualquier técnica para extraer, almacenar o transferir información de forma masiva.

Además, sus datos vienen de la API de X, consultada una vez por hora.

`getdaytrends.com/es/help/#terms`

¿Lo que vamos a hacer hoy respeta estos términos?





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Acceso legítimo $\neq$ Uso ilimitado

Una fotografía puede ser pública y, aun así:

Estar protegida por derechos de autor

Contener datos personales

No poder reutilizarse libremente

Requerir citar su procedencia

Acceder a una información y utilizarla son cuestiones diferentes.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Lo que NO es OSINT

No forman parte de una investigación OSINT:

✗ Acceder a sistemas sin autorización.

✗ Romper contraseñas.

✗ Instalar malware.

✗ Explotar vulnerabilidades.

✗ Interceptar comunicaciones.

✗ Comprar bases de datos obtenidas ilícitamente.

OSINT no es hacking.





Taller OSINT – Bloque 1 · Selenium

Demo 1 · Los TT de hoy

- 01 Preparar Chrome en Colab
- 02 Abrir el navegador (headless)
- 03 Cargar la página y esperar a la tabla
- 04 Extraer las 50 tendencias, también las ocultas
- 05 Pasarlas a un DataFrame
- 06 Guardar la evidencia: HTML, captura, CSV y hash



Checkpoint

Todos tenéis un DataFrame con 50 filas: posición, tendencia, enlace y hora de captura.

Notebook

`01_getdaytrends.ipynb`

Basado en el notebook de Pablo Chamoso.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Preservación de evidencias digitales

La información en Internet puede desaparecer en cualquier momento.

Por ello es recomendable conservar:

01
URL

02
Fecha y hora de
acceso

03
Capturas de
pantalla

04
Documento
original cuando
sea posible

05
Contexto de
obtención

No basta con encontrar una evidencia; hay que poder demostrar cómo se obtuvo.





Tema 1 – Introducción a la inteligencia de fuentes abiertas (OSINT)

Caso práctico

Un investigador encuentra una publicación relevante en una red social.

¿Qué debería hacer?

A) Guardar únicamente el enlace

B) Hacer una captura de pantalla

C) Registrar la fecha y hora

D) Conservar la URL completa

E) Anotar el contexto de la publicación

¿Qué opción proporciona mayores garantías?





Taller OSINT – Bloque 1 · Selenium

Demo 2 · La crisis de Ceuta en los TT

Pregunta de inteligencia: ¿qué presencia tuvo la crisis migratoria de Ceuta en los TT de España entre el 10 de agosto y el 18 de septiembre de 2026?



Un día

Los 50 TT de un día y una hora concretos



40 días

El mismo código dentro de un bucle, con pausas



Filtrar

Palabras clave: Ceuta, Tarajal, frontera...



Cronología

Cuándo aparece, cuánto dura, qué posición



Aparecerán hashtags ofensivos: analizamos narrativas, no las suscribimos.

Notebook de demostración: 02_ceuta.ipynb (no se reparte).





Taller OSINT – Bloque 1 · Selenium

Tarea: TT de septiembre a las 22:00

Enunciado

Ampliando el notebook de clase, obtén de getdaytrends los 50 trending topics de España de cada día de septiembre en prime time (22:00).

Individual · 10 % de la nota de participación.

Plazo y entrega: [por fijar] · Studium

De lo más sencillo a lo más complicado:

- 1 El día actual, 10 TT
- 2 El día actual, los 50
- 3 El día 1 del mes
- 4 El día 1 del mes a las 22:00
- 5 Todos los días del mes

 **Ojo: la web muestra la hora en UTC. Las 22:00 en España en septiembre son las 20:00 UTC.**





RSS: la noticia detrás del TT



RSS (Really Simple Syndication) es un fichero XML que publica un sitio web con sus últimas entradas, pensado para que lo lean programas y no personas. Atom es un formato hermano que hace lo mismo.

Lo publica el propio sitio

Se consume con permiso implícito

Datos ya estructurados

Titular, enlace, fecha y fuente separados

Sirve para vigilar

Consultarlo cada cierto tiempo
= alertas

Antes de hacer scraping de una web de noticias, buscad su feed.





Anatomía de un feed

```
<rss version="2.0">
  <channel>
    <title>Portada · Diario</title>
    <item>
      <title>Titular de la noticia</title>
      <link>https://diario.es/noticia</link>
      <pubDate>Wed, 23 Sep 2026 10:15 GMT</pubDate>
      <description>Resumen...</description>
      <guid>https://diario.es/noticia</guid>
    </item>
    <item> ... </item>
  </channel>
</rss>
```

channel El sitio que publica

item Cada noticia

title · link Titular y URL del artículo

pubDate Fecha de publicación

description Resumen, no el texto completo

guid Identificador único: evita duplicados





Taller OSINT – Bloque 1 · RSS

Cómo encontrar el feed de un sitio

01



Buscar el icono

Icono naranja o enlace
"RSS" / "Feeds",
normalmente en el pie

El más rápido, cuando existe.

02



Probar rutas típicas

```
/feed  
/rss  
/rss.xml
```

Los sitios con WordPress tienen /
feed/ casi siempre.

03



Mirar el código fuente

```
<link rel="alternate"  
type="application/  
rss+xml" href="...">
```

El más fiable: el sitio declara dónde
está su feed.

Para leerlos sin programar: lectores como Inoreader o Feedly. Google Alerts también puede entregar sus avisos como feed.





Taller OSINT – Bloque 1 · RSS

Google News como buscador por RSS

```
news.google.com/rss/search?q=Ceuta+when:7d&hl=es&gl=ES&ceid=ES:es
```

q = la búsqueda

Admite operadores del buscador:

```
"crisis migratoria" # frase exacta
Ceuta OR Tarajal    # alternativas
site:rtve.es        # un medio
when:7d              # últimos 7 días
```

hl · gl · ceid = idioma y país

Qué edición de Google News consultamos. Con ES:es, noticias en español de medios de España.

Un buscador de noticias que devuelve datos estructurados, sin scraping.





Taller OSINT – Bloque 1 · RSS

RSS frente a scraping



Ventajas

Legítimo: el sitio lo publica para consumirlo

Estable: no depende del diseño de la web

Ligero: una petición, sin navegador

Evidencia: fecha, enlace e id de serie



Limitaciones

Solo lo reciente: últimas 20–100 entradas, sin archivo

Resumen: el texto completo hay que descargarlo

No siempre existe: algunos sitios lo han abandonado

Derechos: leer no es republicar

Para histórico: hemerotecas o GDELT, que indexa noticias de todo el mundo desde hace años.





Taller OSINT – Bloque 1 · RSS

Del TT a la noticia




Retroalimentación: lo que obtenemos en un paso se convierte en la pregunta del siguiente.

Notebook: 03_rss.ipynb





De 132 noticias a un grafo de inteligencia



Obsidian + IA

Convertir un montón de noticias en una red de personas, lugares, organizaciones y eventos que se puede consultar, y comprobar que cada dato tiene su fuente.

Caso de estudio: la desaparición de Madeleine McCann (Praia da Luz, 2007). Muchos años de cobertura, muchos países, muchos actores.





Taller OSINT – Bloque 3 · Obsidian

Dos horas: diapositivas, tres demos y vuestro análisis

Intro

DEMO 1

Caso

DEMO 2

DEMO 3

Mapas

ANÁLISIS

Límites y ética

Cierre

0

10

22

27

40

70

75

95

110

120



DEMO 1

Obsidian con una familia inventada: notas, enlaces, grafo y un mapa a mano.



DEMO 2

Recoger: RSS en Colab, el script del buscador y apartar lo que no es noticia.



DEMO 3

Skills de kepano, defuddle, el vault con 10 noticias y la IA.



ANÁLISIS

Vosotros: grafo, mapa de vínculos y preguntas de inteligencia.

Todo lo que hago en pantalla está en la guía paso a paso: podéis seguirme o repetirlo en casa.





Taller OSINT – Bloque 3 · Obsidian

Un vault de Obsidian es una carpeta de ficheros de texto



Nota

Un fichero .md (Markdown) en tu disco. Se abre con cualquier editor.



Enlace

[[Nombre]] apunta a otra nota, aunque todavía no exista.



Backlink

Cada nota sabe quién la menciona. ¿Dónde más aparece esto?



Propiedades

Campos entre --- al principio: tipo, fecha, fuentes...



Grafo

Cada nota es un punto y cada enlace, una línea.



Local

Nada sale de tu ordenador si no quieres. En OSINT, importa.



DEMO 1

Obsidian con una familia inventada

Abre

- Obsidian → Crear bóveda nueva → demo_familia
- Documento demo1_familia.md (al lado)
- Cuatro personas, tres lugares, un evento

En la guía

Parte 1 · paso 1

Tiempo

min 10 – 22



Taller OSINT – Bloque 3 · Obsidian

Lo mismo que con la familia, pero con 130 noticias

```
---
tipo: persona
alias: [Gerry]
n_fuentes: 67
---

Padre de [[Madeleine McCann]].
Declarado «arguido» en 2007
([[2007-09-08 ... named as 'suspect']]).

## Relaciones
- [[Kate McCann]]: su mujer
```

Nota real del vault: entidades/personas/Gerry McCann.md (resumida)

	Familia	Caso McCann
Notas	8	≈ 290
Propiedades	tipo, alias, rol	+ fuentes, n_fuentes
Relaciones	«su marido»	«declaró arguido a»
Quién escribe	Tú, a mano	Una IA con reglas
Regla nueva	—	Cada frase, con su fuente





Taller OSINT – Bloque 3 · Obsidian

El caso en un minuto: 19 años, tres países, tres idiomas

- **2007**
Mayo
Madeleine, de 3 años, desaparece del apartamento familiar en Praia da Luz (Algarve, Portugal).
- **2007**
Sept.
La policía portuguesa declara «arguidos» (sospechosos formales) a los padres.
- **2008**
Julio
Portugal archiva la investigación y levanta ese estatus.
- **2011**
Scotland Yard revisa el caso.
- **2020**
Junio
La fiscalía alemana anuncia que investiga a un alemán por su muerte.
- **hoy**
Sin nadie condenado por la desaparición. El caso sigue en los medios.



Por qué este caso

Muchos años de cobertura, en varios países e idiomas, y muchos actores.



Con cuidado


Personas reales. Sospechoso no es culpable; investigado no es condenado.





Taller OSINT – Bloque 3 · Obsidian

El recorrido completo: el RSS da enlaces; el texto llega después



Parte 2 de la guía: pasos 2-4 · Parte 3: pasos 5-8 · Parte 4: pasos 9-11 · Partes 5-6: ver y analizar

El RSS no nos da las noticias: nos dice dónde están. El script del buscador sí trae el texto.





Dos formas de recoger noticias, dos sesgos distintos

	RSS de Google News (05B)	Buscador (script ddgs)
Qué trae	Titular, medio, fecha y enlace, sin el texto	URL y texto del artículo
Tiempo	Ventanas after:/before:, toda la historia	Lo reciente
Criterio	Explícito: puntos y motivo	Palabras clave en el texto
Ruido	Bajo	Wikipedia, Netflix, páginas de tema
Resultado	113 noticias, 2007-2026	26 resultados, 6 no eran noticias

Ninguna fuente es neutra: hay que saber qué deja fuera cada una.





Taller OSINT – Bloque 3 · Obsidian

El RSS cubre 19 años; el buscador, solo los dos últimos



Buscador

Los 20 resultados buenos son de 2024-2026 o no tienen fecha.



Pregunta

¿Por qué 2007 no sale sin ventanas, si fue cuando más se publicó?

Máximo 4 noticias por ventana; 2007 va mes a mes y 2008 por trimestres.



DEMO 2

Recoger los datos

Abre

- Colab → subir herramientas/05B (modo clase)
- Terminal en taller_demo/ (entorno virtual)
- descargas_en_vivo/ para lo que bajemos ahora

En la guía

Parte 2 · pasos 2 – 4

Tiempo

min 27 – 40



Taller OSINT – Bloque 3 · Obsidian

Un buscador también devuelve lo que no es una noticia



Wikipedia

dominio no periodístico



Ficha de Netflix

dominio no periodístico



ABC · «últimas noticias»

titular de listado



Univision · /temas/

página de tema



La Voz de Galicia · /temas/

página de tema



RTVE · /temas/

página de tema

```
$ python separar_no_noticias.py
noticias
[DESCARTAR] Madeleine McCann- RTVE.es
    → página de tema (/temas/)
...
6 de 26 no parecen noticias.
Esto ha sido una SIMULACIÓN.
```

Simula primero; mueve (no borra) con --mover

Si entra Wikipedia, la IA extrae entidades de algo que no es prensa.





Taller OSINT – Bloque 3 · Obsidian

defuddle trae el artículo... salvo tras un muro de pago

```
$ defuddle parse https://www.theguardian.com/... --md
```

```
British toddler goes missing in Algarve
```

```
A three-year-old British girl  
has gone missing...
```

Página web → solo el artículo, en Markdown. Sin menús, anuncios ni cookies.

79 / 113

noticias del RSS con texto (caso completo)

402

Payment Required

The Telegraph: 14 de 14 fuera.

Todo un medio entra solo con sus titulares.

11 de los 34 fallos son de 2007: el año clave es el que peor se descarga.

Lo que falla no se borra: queda con su titular y marcado como texto: fallo.



Taller OSINT – Bloque 3 · Obsidian

Una skill es un manual en Markdown escrito para una IA

```
---
name: defuddle
description: Extract clean Markdown from
  HTML pages with Defuddle CLI.
---

If not installed: npm install -g defuddle

Always use --md for markdown output:

defuddle parse <url> --md
```

github.com/kepano/obsidian-skills · [skills/defuddle/SKILL.md](#) (extracto)

obsidian-markdown

json-canvas

defuddle

obsidian-bases

obsidian-cli

knap



Se lee bajo demanda

La IA solo ve el nombre y la descripción hasta que la necesita. De Steph Ango (kepano), CEO de Obsidian.



DEMO 3

El vault y la IA, con 10 noticias

Abre

- github.com/kepano/obsidian-skills
- Terminal en taller_demo/ → preparar_vault.py
- Obsidian: abrir vault_demo (ventana nueva)
- Claude Code dentro de vault_demo/

En la guía

Partes 3 – 4 · pasos 5 – 11

Tiempo

min 40 – 70



Esto no es entrenar un modelo: es darle contexto



Entrenar (fine-tuning)

Cambiar los pesos del modelo con miles de ejemplos. Caro, lento, y lo aprendido se queda dentro del modelo.



Dar contexto (estilo RAG)

La IA lee nuestros ficheros en ese momento y trabaja sobre ellos. Al cerrar la conversación, no recuerda nada.

¿Hemos entrenado a Claude con estas noticias? No: se las hemos dado a leer.





Taller OSINT – Bloque 3 · Obsidian · mientras la IA trabaja

Las reglas del vault convierten a la IA en un analista prudente



1 · Cada afirmación, con su fuente

Frase sin enlace a una noticia, frase que no se escribe.



3 · Antes de crear, buscar

Si ya existe (o un alias), se actualiza; no se duplica.



5b · Quién actúa

En cada evento, quién lo ejecutó: qué policía, qué fiscalía.



6 · Lenguaje de las fuentes

«Sospechoso», «arguido» y «condenado» no son sinónimos.

CLAUDE.md en la raíz del vault. Otros agentes leen AGENTS.md o GEMINI.md: mismo contenido.





Taller OSINT – Bloque 3 · Obsidian

La IA no dedujo una identidad que la fuente no daba



Identificación

La noticia de 2020 habla de un «alemán de 43 años» investigado por asesinato, pero no da su nombre. Que sea Brueckner solo se deduce de la noticia de 2026. **Por eso no se enlaza desde la noticia de 2020.**

Aviso que escribió la IA en entidades/personas/Christian Brueckner.md



Lo mismo con testigos

Una testigo sin identificar no se enlazó a Jane Tanner.



¿Lo habríais enlazado vosotros?

La IA «sabía» quién era; la fuente no lo decía.





Taller OSINT – Bloque 3 · Obsidian

Las fuentes se contradicen y el vault lo muestra



Fecha en que Murat pasó a ser arguido

12 de mayo (The Guardian) · 14 de mayo (The Mirror)



Distancia del restaurante al apartamento

200 yardas · «menos de un minuto» · 50 metros



Personas interrogadas por la policía

11 (BBC) · 4 (The Independent)



Color del pijama

Blanco (The Guardian) · Rosa (BBC)


32 entidades tienen al menos un aviso de contradicción. Buscadlas: [!warning]





Taller OSINT – Bloque 3 · Obsidian


El grafo crece en dos polos: Portugal y Alemania



Lote 1 · 2007



Lote 4 · hasta 2012




Final · 2026


¿Qué entidades unen las dos fases del caso?



Un mapa de fuentes no es un mapa de vínculos



Grafo de Obsidian: ¿quién sale en qué noticia? Líneas sin tipo.



Canvas (json-canvas): ¿quién se relaciona con quién, y cómo? Flechas con dirección y etiqueta.



Taller OSINT – Bloque 3 · Obsidian

Filtros y colores convierten la maraña en un mapa

Ajuste	Valor	Para qué
Filtro	<code>path:entidades OR path:noticias</code>	Fuera reglas e informes
Huérfanas	desactivado	Quita lo que no conecta
Grupos	<code>path:entidades/personas ...</code>	Un color por tipo
Repulsión	más alta	Que no sea una bola
Solo entidades	<code>path:entidades</code>	La red sin las noticias



Grafo local

Menú ... de una nota → Abrir grafo local, profundidad 2.



Ya configurado

El vault que os descargáis trae los colores y filtros.



ANÁLISIS

Vuestro turno: mirar el vault

Abre

- Vuestro vault_demo (10 noticias)
- o el vault completo: checkpoint_1 en Moodle
- Por parejas · citad la nota o la vista que usáis

En la guía

Partes 5 – 6 · pasos 12 – 13 y ejercicios

Tiempo

min 75 – 95



Taller OSINT – Bloque 3 · Obsidian

Siete preguntas, siete formas de mirar el vault

1 Grafo local
¿Con quién se relaciona Brueckner? ¿De qué países son sus organizaciones?

2 Backlinks
¿Cuántas noticias citan Praia da Luz, y de qué años?

3 [!warning]
Una contradicción entre medios: ¿qué fuente es más fiable?

4 [n_fuentes:1]
Una entidad con una sola fuente: ¿la meteríais en un informe?

5 Filtro por tipo
¿Qué organización ejecuta más eventos? ¿Desde cuándo?

6 Canvas
Tres flechas del mapa de vínculos: ¿están bien?

7 · ¿Qué nos falta? Comparad vuestro vault de 10 noticias con el completo.

Guía, parte 6. Apuntad qué nota o qué vista usáis para responder.





Taller OSINT – Bloque 3 · Obsidian

Cada pieza del proceso deja algo fuera



53 de 153

entidades con una sola fuente

34 de 113

noticias RSS sin texto completo





Taller OSINT – Bloque 3 · Obsidian

Juntar lo publicado también crea información nueva



Personas reales

Algunas investigadas y nunca condenadas por el caso. Una familia que sigue buscando.



Agregar es crear

Una ficha junta lo que estaba disperso en cien noticias. Lo mismo que vimos con Sherlock.



Atribuir es grave

Un error de atribución sobre una persona, en inteligencia, no es un detalle.



La IA creó una ficha para la madre de un investigado porque sale en una noticia. ¿Debe estar en vuestra base de datos?

El vault es un ejercicio: no se publica ni se comparte fuera de la asignatura.





Pregunta de comprobación

Un compañero entrega un informe hecho con este vault: «Christian Brueckner era el sospechoso desde 2020, según 40 fuentes».

✓☰ ¿Qué comprobaríais primero?

Pista: la noticia de 2020 y la regla 1.

⚖️ ¿Qué palabra cambiaríais?

Pista: sospechoso, investigado, acusado...





Taller OSINT – Bloque 3 · Obsidian

Cada pieza tiene su papel, y la última sois vosotros



RSS

descubre




defuddle

extrae



La IA

estructura



Obsidian

muestra



Tú

verificas

`guia_taller_paso_a_paso.md`

Lo de hoy, con 10 noticias

`guia_completa_en_casa.md`

El caso completo, por lotes

`taller_demo.zip`

Kit con datos y puntos de control

